

问题二阶段成果报告

基于能力互补性的场景效用评价

最小信息偏移场景权重 + CES 互补型效用
科研长文本分析 · 大众日常通用对话 · 计算机代码开发



状态：Q2 数学模型、工程框架、接口、测试与论文方法已完成
边界：未运行 Q1，未读取 Q1 半成品，未生成正式排名

待 Q1 冻结后注入最终能力向量即可进入正式运行阶段

1. 执行摘要

本阶段已在不依赖 Q1 尚未冻结结果的前提下，完成问题二的数学模型、工程实现、数据接口、缺失处理、敏感性分析、图表程序和论文方法章节。主模型统一为“Q1 基础能力向量 - 场景需求约束 - KL 最小信息偏移权重 - CES 能力互补型效用”。

所有开发验证均使用 Model_A 至 Model_F 的匿名虚拟数据，并明确标记 **MOCK_DATA_ONLY = TRUE**。未读取或运行 Q1 半成品，未向正式结果目录写入任何排名，也未形成 Kimi K3 或其他真实模型的场景结论。

成果模块	状态	交付内容
数学模型	已完成	KL 场景权重、CES 主效用、线性基准、PRI
解释机制	已完成	CES 内层份额、边际效用、效用弹性、成对差异
稳健性	已完成	$\alpha \times \rho$ 网格、先验对照、排名突变、缺失区间
工程与接口	已完成	Q1 适配层、冻结保护、受控输出、目标模型分析
论文与文档	已完成	Q2 方法 LaTeX、Q1→Q2 交接、Tool Use 报告
正式排名	未执行	必须等待 Q1 finalized=true 后运行

最终核查：Q1_MODIFIED = false；18 项单元与 mock 集成测试全部通过；Q2 测试缓存已清理。

2. 问题定位与总体模型主线

Q1 回答“模型具有什么基础能力”，Q2 回答“这些能力进入不同现实场景后能产生多大的使用效用”。因此 Q2 不重新构建 Benchmark 能力体系，而是继承 Q1 冻结后的统一能力空间。




图 1 Q2 的 KL-CES 场景效用评价主线

核心创新：场景不仅改变能力的重要程度，也改变不同能力之间的可替代程度。第一层用场景约束和 KL 投影确定重要性结构 w；第二层用 CES 参数 ρ 描述替代结构。

五维基础能力

维度	能力含义	在 Q2 中的主要作用
C1	复杂推理能力	三场景均重要；科研与代码的核心协同能力
C2	知识与事实可靠性	科研可信性与日常对话可靠性的关键支撑
C3	长上下文处理能力	科研长文本核心；支持连续对话与代码上下文
C4	代码与软件工程能力	计算机代码开发场景的核心能力
C5	多模态能力	大众通用对话中的交互扩展能力

3. Q1 → Q2 标准数据接口

Q2 通过独立适配层读取标准 CSV 与 metadata JSON，不导入 src/q1，不依赖 Q1 的内部文件结构、Bradley-Terry 成对比较过程或当前输出文件名。未来如果 Q1 调整导出形式，只需修改 data_adapter.py。

类别	字段	要求
必须	model	非空、唯一；正式目标模型名称需保持一致
必须	C1, C2, C3, C4, C5	0-100 或 0-1，由 metadata 声明；允许 NA
必须	C1_available ... C5_available	布尔值；标记不可用时，对应能力强制视为 NA
必须	objective_weights	C1-C5 严格为正；作为 KL 中性参考先验
冻结	q1_finalized / version / date	进入 FINAL 模式的必要条件
可选	q1_overall_score / rank	用于描述与排名迁移，不是主模型必要输入
可选	C1_lower ... C5_upper	用于区间传播和最好/最差可能排名

运行保护

DEVELOPMENT 模式只接受 CSV 与 metadata 双重标记的匿名 mock 数据；FINAL 模式必须同时满足 q1_finalized=true、冻结版本非空、冻结日期非空、Q1 客观权重可用。任一条件缺失即拒绝运行。

模式	允许的输入	允许的输出位置	命名保护
DEVELOPMENT	仅 MOCK_DATA_ONLY	outputs/q2/dev/	自动添加 MOCK_DATA_ONLY —
FINAL	仅冻结 Q1 数据	outputs/q2/final/	要求冻结 metadata

4. 第一层：最小信息偏移场景权重

Q1 客观权重反映五类能力在公开评测数据中的信息贡献、非冗余性与稳定性，可作为缺乏具体场景偏好时的中性参考分布，但不能直接视为现实场景价值权重。对每个场景，在满足需求约束的前提下寻找相对于中性先验偏移最小的权重。

$$\min D_{KL}(w^{(s)} \parallel w^{(0)}) = \sum_j w_j^{(s)} \ln [w_j^{(s)} / w_j^{(0)}]$$

约束包括 $w_j \geq 0$ 、 $\sum w_j = 1$ ，以及核心能力总权重、单项能力下界和重要性顺序。程序先用线性规划寻找可行点，再用 SLSQP 完成 KL 投影，并输出约束残差诊断。

场景	核心能力约束	辅助约束示例	开发区间
科研长文本	$wC1 + wC2 + wC3 \geq \alpha R$	$wC3 \geq wC4$; $wC1 \geq wC5$; $wC2 \geq wC4$	α : 0.55-0.75; p : -0.60-0.20

场景	核心能力约束	辅助约束示例	开发区间
大众对话	$wC1+wC2+wC5 \geq \alpha D$	$wC2 \geq 0.15$; $C1/C2/C5$ 不低于 $C4$	α : 0.50-0.70; ρ : 0.10-0.80
代码开发	$wC4+wC1 \geq \alpha C$	$wC4 \geq 0.30$; $wC4 \geq C2/C3$; $wC1 \geq C5$	α : 0.55-0.75; ρ : -0.70-0.20

上述区间均集中保存在 config.py，并标记为
TENTATIVE_PARAMETER_RANGE=true。它们是敏感性分析范围，不是已经冻结的最终参数。

双参考先验

正式运行时同时比较 Q1 客观权重先验与等权先验 (1/m,...,1/m)。如果模型在两种先验下保持相近的平均排名与 Top3 比例，说明结论不依赖单一权重基础。

5. 第二层：CES 能力互补型效用

普通线性加权隐含较强的完全补偿性，一项能力很高可以抵消另一项关键能力严重不足。科研长文本和代码开发通常需要多项能力共同达到较高水平，因此采用 CES 表达能力间的不完全替代关系。

$$U_i^{(s)} = [\sum_j w_j^{(s)} (z_{ij}^* + \epsilon)^{\rho s}]^{1/\rho s}$$
，其中 z^* 为归一化能力， $\epsilon = 10^{-6}$

参数情形	模型极限	解释
$\rho \rightarrow 1$	接近线性加权	能力之间具有较强替代性
$\rho \rightarrow 0$	加权几何平均	偏科受到更强惩罚
$\rho < 0$	互补性进一步增强	关键短板显著压低场景效用

线性基准与能力失衡惩罚

$$L_i^{(s)} = \sum_j w_j^{(s)} z_{ij}^* \quad PRI_i^{(s)} = [L_i^{(s)} - U_i^{(s)}] / L_i^{(s)}$$

线性模型只是完全补偿型 Baseline。PRI 衡量模型因关键能力结构不均衡，在互补型场景中相对于线性评价损失的效用比例。程序同时输出 CES 排名、线性排名和两者的名次差。

6. CES 非线性解释与竞争差异

CES 是非线性函数，因此不能把 wjzj 直接称为 CES 能力贡献。Q2 实现了内层聚合份额、边际效用和效用弹性三组解释量。

$$q_{ij}^{(s)} = w_i^{(s)}(z_{ij}^* + \epsilon)^{\rho s} / \sum_k w_k^{(s)}(z_{ik}^* + \epsilon)^{\rho s}$$

$$\partial U_i^{(s)} / \partial z_{ij}^* = w_i^{(s)}(z_{ij}^* + \epsilon)^{\rho s - 1} (U_i^{(s)})^{1 - \rho s}$$

$$E_{ij}^{(s)} = (\partial U_i^{(s)} / \partial z_{ij}^*) \cdot z_{ij}^* / U_i^{(s)}$$

内层份额用于描述 CES 聚合结构；边际效用回答“改善哪项能力最能提高特定场景效用”；效用弹性用于比较不同能力改善 1% 对效用的相对影响。解析边际效用已通过数值微分验证。

模型成对比较与目标模型分析

函数	自动输出
compare_models(a,b,scene)	场景效用差、原始能力差、加权能力效应、CES 曲率效应、内层份额、边际改善方向、PRI 与短板惩罚
analyze_target_model()	目标模型三场景排名、效用、PRI、份额、边际效用、排名迁移、敏感性与主要竞争模型

目标分析函数默认名称为 Kimi K3，但当前没有用真实数据调用。正式阶段的竞争模型将根据结果自动识别排名上一位、下一位、场景第一名和效用最接近模型，不提前人工指定。

7. 排名迁移与二维稳健性

$$\Delta R_i^{(s)} = R_i^{(s)} - R_i^{(0)}$$

由于名次 1 最优， $\Delta R < 0$ 表示进入场景后排名上升， $\Delta R > 0$ 表示排名下降。若 Q1 最终综合排名不适合作为统一基线，Bump Chart 会自动退化为三个场景之间的迁移图。

$\alpha \times \rho$ 二维参数网格

对每个场景，在每一个 (α, ρ) 网格点重新求解 KL 权重，再重新计算 CES 效用与排名。由此研究 $\text{Rank}_i = f(\alpha, \rho)$ ，避免使用单一拍脑袋参数。

输出指标	含义
平均 / 最好 / 最差排名	模型在参数区间中的总体位置和边界
Top3 比例	模型处于前 3 名稳定区域的覆盖率
排名标准差	参数扰动下排名波动程度
排名突变区间	固定 ρ 时，排名在相邻 α 网格间变化的具体阈值区间
先验偏移	Q1 客观先验与等权先验的平均排名和 Top3 比例变化

图表框架包括排名迁移 Bump Chart 与二维排名稳定区域热力图。Mock 测试中图片仅写入临时目录，并在测试后删除。

8. C5 缺失与区间传播

模式	处理方式	结果标记 / 保护
complete_case	只比较参与维度全部可观测的模型	记录被排除模型
common_dimension	使用所有模型共同可观测维度，并重新求解 KL 权重	COMMON_DIMENSION_RESULT
interval_propagation	由能力上下界传播 CES 效用上下界与可能排名	缺上下界时拒绝运行
q1_final_policy	继承 Q1 已冻结的统一缺失处理	要求 metadata 明确声明

总原则：Q2 不把 NA 填 0，不擅自生成不存在的能力值。若某能力点值已观测，区间缺失时可视为退化区间；若点值缺失，则上下界必须由 Q1 提供。

可能排名区间

对模型 i ，最好可能排名使用“本模型取效用上界、其他模型取效用下界”计算；最差可能排名使用“本模型取效用下界、其他模型取效用上界”计算。该方法不会人为选择缺失能力的点估计。

9. Tool Use / Agent Ability 可行性检查

本检查只读取 frozen/v1.0 的冻结数据和数据说明，不重新采集数据，不运行 Q1。冻结建模矩阵共有 10 个模型。

指标 / 协议	最终选中模型数	主要问题
FrontierSWE · Agent harness	6	只覆盖同一组 6 个模型

指标 / 协议	最终选中模型数	主要问题
ProgramBench · Agent harness	6	与上一组重合，仍非全模型覆盖
SWE-bench Verified · Agent/tools	2	覆盖另一组 2 个 DeepSeek 变体，协议不同

结论：**当前不建议新增 C6**。现有工具/Agent 指标没有形成覆盖全部模型、版本一致、harness 一致、工具权限一致的统一量尺；不同协议组无法直接拼接；软件工程 Agent 指标还已部分进入 C4，单列 C6 会造成重复计权。

论文限制表述：受公开一致性工具调用数据覆盖不足及 Agent 评测协议差异限制，本文未单列工具调用维度，而主要由代码与软件工程能力及复杂推理能力共同表征代码开发需求。

10. 工程文件与职责

文件	职责
config.py	能力定义、EPS、三场景 α/p 区间、需求约束和等权先验
data_adapter.py / normalize.py	Q1 标准接口、冻结校验、量纲转换、availability 处理
scene_constraints.py / kl_weights.py	约束动态激活、可行性 LP、KL 投影和残差诊断
ces.py / linear_baseline.py	CES 主效用及线性对照
imbalance_penalty.py / marginal_analysis.py	PRI、CES 份额、边际效用、弹性和数值微分
rank_migration.py / pairwise_analysis.py	排名迁移、竞争模型识别、目标模型自动分析
missing_policy.py / sensitivity.py	四种缺失策略、区间传播、 $\alpha \times p$ 与先验稳健性
plotting.py / pipeline.py	Bump Chart、热力图、受保护的内存管线和受控写出

数据与文档

路径	内容
data/q2/	最小模板、final 模板、metadata 模板、匿名 mock 数据
docs/q1_to_q2_interface.md	字段、量纲、冻结条件、可选区间和交接清单
docs/q2_tooluse_feasibility_report.md	Agent/Tool 数据覆盖与是否新增 C6 的证据
sections/q2.tex	完整 Q2 方法章节，不含正式结果
tests/test_q2.py	18 项数学、接口、缺失、稳健性、绘图和保护测试

11. 测试与验证证据

测试使用 Python 标准库 unittest，避免增加 pytest 依赖。最终执行结果为：Ran 18 tests, OK。

测试组	验证内容
KL 权重	优化收敛、非负、和为 1、核心权重、下界与顺序约束
CES 极限	$p=1$ 等于线性； $p=0$ 等于加权几何平均
非线性解释	PRI 符号、内层份额和为 1、解析边际与数值差分一致
缺失处理	NA 不变 0；complete-case、common-dimension、interval propagation

测试组	验证内容
集成与稳健性	三场景管线、排名迁移、二维网格、先验对照、目标模型分析
保护与绘图	未标记数据拒绝、FINAL 冻结拒绝、输出目录保护、临时图表生成

本机没有安装 XeLaTeX、LuaLaTeX、pdfLaTeX、Tectonic 或 latexmk，因此 sections/q2.tex 尚未做本地编译验证；其数学环境与章节结构已检查，后续并入主文档时需在具有 LaTeX 环境的机器上编译一次。

12. 必须等待 Q1 冻结的工作

- 注入真实模型的 C1-C5 能力向量与 availability flags;
- 读取 Q1 最终客观权重，并与等权先验做正式对照；
- 统一论证并冻结三场景 α 与 ρ 的正式区间；
- 选择主缺失处理口径，并运行区间稳健性对照；
- 生成三个场景的正式 KL 权重、CES 效用、PRI 与排名；
- 生成正式排名迁移图和二维稳定区域图；
- 运行 Kimi K3 目标分析并自动识别主要竞争模型；
- 将真实表格、图和结论写入论文结果部分；
- 仅在冻结保护通过后向 outputs/q2/final/ 写入结果。

当前目标已实现：Q2 不再依赖 Q1 的开发进度；Q1 成员冻结并交付一份标准 CSV 与 metadata JSON 后，即可直接进入正式运行阶段。

13. 交付结论

问题二已形成完整、独立且受保护的 KL-CES 场景效用评价框架。模型在重要性结构上通过 KL 最小信息偏移避免纯人工直接赋权，在可替代结构上通过 CES 对关键能力协同与短板效应进行建模，并通过 PRI、边际效用、排名迁移、二维参数网格、先验对照和缺失区间传播形成可解释、可复核的稳健性体系。

本阶段没有得出任何真实模型的场景排名。所有最终结论必须以 Q1 冻结能力向量为输入后重新计算。

最终核查项	结论
是否修改 src/q1 或 Q1 数据	否
是否运行 Q1	否
是否使用 Q1 半成品形成正式结果	否
是否生成真实模型排名	否
Q2 是否可在 Q1 冻结后直接注入数据运行	是

报告生成位置：output/pdf/Q2_KL-CES_阶段成果报告.pdf