

数学建模竞赛 B 题 问题一 Q1 v1.1

1 问题一：主流大语言模型综合性能评价（Q1 v1.1）

1.1 4.1 问题分析

本文保留 v1.0 的 Missing-aware Spearman、Benchmark Family 分层、Family-balanced Margin-weighted Pairwise Comparison、正则化 Bradley–Terry 及 C1–C5 多维体系。v1.1 仅修正 C5 适用性、稳定性、综合排名层次、来源集中度和论文审计表达，不改变 frozen/v1.0 中的任何成绩。

1.2 4.2 数据与指标体系

冻结数据包含 10 个模型、21 个 Exact Settings、14 个 Benchmark Families 和 164 条有效观测（覆盖率 0.780952）。五个能力维度仍为 C1 复杂推理、C2 知识与事实可靠性、C3 长上下文、C4 代码与软件工程和 C5 多模态。正式来源按 registry 汇总为 LiveBench、Artificial Analysis、官方技术报告/模型卡、Kimi 官方技术比较和第三方标准化平台，详见 `tables/paper_table_q1_v11_sources.xlsx`。

对 C5 缺失进行适用性审计。DeepSeek-V4-Pro Max 和 DeepSeek-V4-Flash Max 由 SRC003 技术报告判定为 Type A（结构性能力缺位）；GLM-5.2 的冻结证据不足以区分能力缺位与测评缺失，标记为 `REQUIRES_MANUAL_CONFIRMATION`，不得赋 benchmark 分数 0。其余七个模型属于 Type C（至少有一项正式 C5 观测），部分缺少另一项 benchmark 的记录仍保留为 benchmark missing。

令多模态可用性为 $A_i \in \{0, 1\}$ ，则 $S_{i5}^* = A_i S_{i5}^{BT}$ 。这里 Type A 的 0 只表示综合能力体系中的可用性为 0，不是把 MMMU-Pro 或 MathVision 的原始分数伪造为 0；Type B 仍为 NA。

1.3 4.3 指标相关性和筛选

筛选分为两层：21 个 Exact Settings 先按同源、同任务或同一 Benchmark 归并为 14 个 Families；随后综合 $|\rho|$ 、共同样本数 n_{jk} 、模型覆盖率、语义独立性、比较网络连通性和来源独立性进行关键性审查。 $|\rho| \geq 0.85$ 仅作为冗余候选标记。对于 $n = 3$ 的高相关指标以及承担网络桥接作用的指标，采用“保留—冗余标记—敏感性删除”，不机械删除。详细表见 `tables/paper_table_q1_v11_indicator_screening.xlsx`。

1.4 4.4 成对比较构造

成对比较、Margin 权重和 Family balancing 与 v1.0 相同，仅对同一 Exact Setting 的有效观测构造关系，缺失值不插补。

1.5 4.5 Bradley–Terry

继续使用带 L_2 正则项的 Bradley–Terry 模型并约束 $\sum_i \theta_{id} = 0$ 。各维度 BT 均收敛，原始 latent ability 先用于稳定性审计，再在维度内转换为 0–100 的解释性分数。

1.6 4.6 五维客观权重

v1.0 的稳定度审计显示 C2、C3、C5 的 $T_d = 1$ 主要源于单 setting Family 在 bootstrap 中始终存在以及每轮 Min-Max 端点固定，属于伪稳定。v1.1 改用 latent ranking stability:

$$T_d = \frac{1 + \text{median}_b \rho_d^{(b)}}{2},$$

其中 $\rho_d^{(b)}$ 为第 b 次 bootstrap 的原始 BT- θ 排名与主模型排名的 Spearman 相关。Ranking A 的新权重为 (0.125734, 0.210410, 0.138221, 0.108204, 0.417432)，权重只表示当前数据集中的有效信息贡献，不代表现实应用中的先验重要程度。

1.7 4.7 综合评价与三类排名

不再输出单一缺失感知榜单。Ranking A 使用 C1-C5*，对九个已解析模型给出统一综合评价，并对 GLM-5.2 给出条件得分区间 [15.417, 57.160]；Ranking B 在全部十个模型上重新计算 C1-C4 权重；Ranking C 仅使用七个具有完整多模态有效信息的模型并重新计算五维权重。正式结果分别见 `paper_table_q1_v11_ranking_A.xlsx`、`paper_table_q1_v11_ranking_B_C1_C4.xlsx` 和 `paper_table_q1_v11_ranking_C_complete_multimodal.xlsx`。

1.8 4.8 稳健性

Bootstrap 保留 2000 次，重采样单位为在固定 Benchmark、来源结构和能力适用性下的成对比较结果，并逐次重新拟合 BT；95% 区间为经验百分位区间。LOFO 检查 Family 删除，LOSO 按正式 source registry 删除来源；网络不连通时标记 NETWORK_DISCONNECTED，不强行计算排名。等权结果仅作为 sensitivity benchmark，详见 `table_q1_v11_equal_weight_sensitivity.xlsx`。

在固定 Benchmark 集合、来源结构及模型能力适用性条件下，Kimi K3 在 Ranking A 的 2000 次 Bootstrap 中进入前三的经验频率为 0.417。该频率不解释为模型客观上必然稳定第三。

1.9 4.9 Kimi K3

Kimi K3 的 Ranking A、B、C 名次分别为 3、2、3。C4 代码与软件工程得分相对 Ranking A 中位数高 31.707，属于 strong evidence advantage。C3 的直接观测仍主要为 AA-LCR，CorpusQA 1M 和 MRCR 1M 缺少直接公开观测，因此只能表述为“在当前 AA-LCR 及模型比较网络下潜在能力高于样本中位水平”，属于 model-inferred advantage / moderate evidence。C5 与完整多模态模型中位数的差值为 -20.513；该差值来自有效 C5 能力比较，不将 Type A 缺位模型的 0 混入多模态同类中位数。

1.10 4.10 小结

v1.1 保留正则化 Bradley-Terry 主线和五维体系，修正了 C5 能力缺位与测评缺失的混淆、稳定度伪稳定、表3覆盖率错误以及来源集中度遗漏。当前唯一未决事项是 GLM-5.2 的 C5 适用性人工确认；在确认前，Q1 不进入最终冻结。