

问题一：主流大语言模型综合性能评价

4 问题一：主流大语言模型综合性能评价

4.1 问题分析与建模思路

大语言模型的综合性能不是单一分数可以充分描述的。本文面对三个困难：其一，不同 Benchmark 的量纲、满分、难度与测试协议不同，原始分数不能直接相加；其二，21 个 Exact Setting 并非相互独立，同源或同类测试可能重复反映相近能力；其三，公开结果存在非随机缺失，缺失可能来自尚未公开，也可能来自模型不具备相应能力。因此，普通加权平均既会混合不可比的量纲，也可能重复计权或把结构性缺位误当作低分。

为此，本文将不可直接比较的绝对分数转化为同一 Exact Setting 内的模型相对胜负关系，再以正则化 Bradley-Terry 模型估计五个能力维度的潜在水平。整体流程为：数据审计与能力适用性识别，21 个 Exact Setting 的两层筛选，Family-balanced Pairwise Comparison，Margin weighting，正则化 BT，C1-C5 能力估计，Information-Redundancy-Ranking Stability 客观赋权，C5 能力适用性修正，Ranking A/B/C，以及 Bootstrap、LOFO、LOSO 和 Kimi K3 竞争力分析。图 1 给出总体结构。



图 1: 问题一总体建模流程。流程图仅表示方法结构，不写入随数据重跑而变化的具体权重。

4.2 数据预处理与评价指标体系

4.2.1 数据来源与数据特征

评价对象为十个具体模型版本。数据包含 21 个 Exact Setting、14 个 Benchmark Family 和 164 条有效观测，理论组合数为 $10 \times 21 = 210$ ，整体覆盖率为

$$\eta = \frac{164}{210} = 0.780952. \quad (1)$$

数据来源包括 LiveBench 官方表格、Artificial Analysis 公共快照、模型官方技术报告或模型卡、Kimi 官方技术材料以及 OpenRouter 的统一端点页面。表 1 列出正文所需的主要来源；所有快照均记录访问日期，详细 source ID 与风险审计保留在配套数据表中。

五个一级能力维度定义为： C_1 复杂推理， C_2 知识与事实可靠性， C_3 长上下文， C_4 代码与软件工程， C_5 多模态。原始分数只在同一 Exact Setting 内参与比较，不进行跨 Benchmark 的直接加总。

表 1: 主要数据来源与用途

Benchmark Family	主要来源	来源类型	用途
LiveBench Logic/Math/Coding	LiveBench 官方表格 (2026-06-25)	统一平台快照	推理、数学与代码
AA-Omniscience/AA-LCR/MMMU-Pro	Artificial Analysis (2026-08-16)	标准化公开榜单	知识、长上下文与多模态
CorpusQA/MRCR/SWE-bench	DeepSeek 官方技术报告	技术报告	长上下文与软件工程
FrontierSWE/ProgramBench/MathVision	Kimi 官方技术材料	官方技术比较	代码与多模态
GPQA Diamond	OpenRouter 统一端点页面	独立比较页面	复杂推理

4.2.2 模型能力适用性处理

对 C5 先核验“是否具备本题定义的原生多模态能力”，再核验是否存在公开 Benchmark。DeepSeek-V4-Pro Max、DeepSeek-V4-Flash Max 和 GLM-5.2 (max) 均被核验为不具备该原生能力。对于这三个模型，原始 MMMU-Pro 与 MathVision 单元仍保持缺失，不改写为 Benchmark 得分 0；只在综合能力体系中令可用性 $A_i = 0$ 。其余七个模型属于具有可估计 C5 潜在能力的多模态模型集合，某一具体 Benchmark 缺失仍按缺失处理。

定义

$$A_i = \begin{cases} 1, & \text{模型具备本题定义的原生多模态能力,} \\ 0, & \text{模型不具备该能力,} \end{cases} \quad S_{i5}^* = A_i S_{i5}^{BT}. \quad (2)$$

因此, $S_{i5}^* = 0$ 只表示综合能力体系中的多模态能力可用性为 0, 不代表模型在 MMMU-Pro、MathVision 等原始测试中的成绩为 0。GLM 的人工核验证据单独记录在 capability applicability 补充表中。

4.2.3 分层评价指标体系

评价层次为“综合性能–能力维度–Benchmark Family–Exact Setting”。Exact Setting 是成对比较的最小单元；Family 用于控制同类指标的隐含权重；能力维度用于形成最终的 C1–C5 结构。C5 的论文展示采用“C5* 多模态有效能力”列，并以 0* 表示结构性能力缺位。

4.3 评价指标相关性分析与筛选

4.3.1 Missing-aware Spearman

对 Benchmark j, k , 令共同有效模型集合为

$$I_{jk} = \{i : x_{ij} \text{ 与 } x_{ik} \text{ 均有效}\}, \quad n_{jk} = |I_{jk}|, \quad (3)$$

并在 I_{jk} 上计算 Spearman 秩相关 ρ_{jk} 。这样既不插补缺失值，也不把缺失模式误当成能力差异。相关性只作为冗余候选的证据，不能替代语义和比较网络判断。

4.3.2 两阶段指标筛选

第一阶段将 21 个 Exact Setting 归并为 14 个 Family；第二阶段综合 $|\rho|$ 、共同样本数、模型覆盖率、语义独立性、比较网络连通性和来源独立性进行筛选。 $|\rho| \geq 0.85$ 只标记高相关候选；若共同样本数很小或该指标承担网络桥接作用，则采用“保留并进行删除敏感性分析”，不机械删除。模型–Exact Setting 覆盖结构见图 2，Family 相关热力图见图 3。




图 2: 模型-Exact Setting 数据覆盖热力图。




图 3: Benchmark Family 的缺失感知 Spearman 相关热力图。

4.4 基于成对比较的五维能力评价模型

对于同一 Exact Setting s 上的模型 i, j ，定义

$$y_{ijs} = \begin{cases} 1, & x_{is} > x_{js}, \\ 0.5, & x_{is} = x_{js}, \\ 0, & x_{is} < x_{js}. \end{cases} \quad (4)$$

任一模型缺少该设置的有效观测时，不构造成对关系。为保留领先幅度，令

$$m_{ijs} = \frac{|x_{is} - x_{js}|}{\max_l x_{ls} - \min_l x_{ls} + \varepsilon}, \quad w_{ijs}^{(m)} = \varepsilon_m + (1 - \varepsilon_m)m_{ijs}, \quad (5)$$

其中 $\varepsilon_m = 0.1$ 。随后在每个能力维度内对 Family 和 Setting 分层归一化，使含有更多设置的 Family 不会自动获得更高权重。该处理将不同量纲的原始成绩转化为同一设置内的可比较信息。

4.5 正则化 Bradley-Terry 模型

第 d 个能力维度中，模型 i 的潜在能力为 θ_{id} ，则

$$P(i \succ j) = \sigma(\theta_{id} - \theta_{jd}) = \frac{\exp(\theta_{id})}{\exp(\theta_{id}) + \exp(\theta_{jd})}. \quad (6)$$

在全部有效成对比较 r 上，采用带 L_2 正则项的加权似然：

$$\hat{\theta}_d = \arg \min_{\theta} \left\{ - \sum_r w_r [y_r \log p_r + (1 - y_r) \log(1 - p_r)] + \frac{\lambda}{2} \sum_i \theta_{id}^2 \right\}, \quad (7)$$

$$\text{s.t.} \quad \sum_i \theta_{id} = 0, \quad \lambda = 1.0. \quad (8)$$

各维度模型均收敛。为便于解释，将同一维度内的 θ 线性转换到 0–100，得到 S_{id}^{BT} ；该转换不改变维度内排序，也不把不同 Benchmark 的原始分数放到同一量纲中。五维能力热力图见图 4。




图 4: 十个模型的 C1–C5 潜在能力标准化得分；C5* 的结构性能零仅在综合评价层使用。

4.6 信息-冗余-稳定性客观赋权

令 S_{id} 为维度内标准化得分, $p_{id} = (S_{id} + \epsilon) / \sum_i (S_{id} + \epsilon)$, 则信息量为

$$I_d = 1 + \frac{1}{\ln n_d} \sum_i p_{id} \ln p_{id}. \quad (9)$$

以维度得分之间的缺失感知秩相关衡量冗余, 定义 $R_d = 1 - D_d^{-1} \sum_{k \neq d} |\rho_{dk}|$ 。稳定度不再依赖 Min-Max 端点, 而由潜在能力排序的一致性给出。设第 b 次 Bootstrap 中维度 d 的 BT- θ 排名与主模型排名的 Spearman 相关为 $\rho_d^{(b)}$, 则

$$T_d = \frac{1 + \text{median}_b \rho_d^{(b)}}{2}, \quad q_d = I_d R_d T_d, \quad w_d = \frac{q_d}{\sum_k q_k}. \quad (10)$$

该定义避免标准化端点造成的机械伪稳定。Ranking A 的五维权重见表 2, 其和为 1。

表 2: Ranking A 的五维客观权重

维度	I_d	R_d	T_d	w_d
C1 复杂推理	0.075410	0.700254	0.575758	0.128212
C2 知识与事实可靠性	0.136024	0.573484	0.618182	0.203358
C3 长上下文	0.061956	0.787390	0.600000	0.123432
C4 代码与软件工程	0.081235	0.611941	0.563636	0.118157
C5 多模态	0.294454	0.583331	0.589286	0.426840

4.7 综合性能评价与模型排名

4.7.1 Ranking A: 统一综合评价

Ranking A 是问题一的主要结果。全部十个模型统一使用 $C_1, C_2, C_3, C_4, C_5^*$, 综合得分为 $G_i = \sum_{d=1}^5 w_d S_{id}^*$ 。表 3 中的 0* 仅表示多模态能力可用性为 0, 不是原始 Benchmark 分数。GPT-5.6 Sol 与 Claude Fable 5 分居前两位, Kimi K3 以 53.720 分列第三; 第一名与第二名差距为 9.676 分, Kimi 与第四名 Gemini-3.1-Pro 的差距仅为 1.443 分, 说明前三之外的相邻名次仍需结合稳健性检验解释。

表 3: Ranking A: 统一 C1-C5* 综合评价

排名	模型	C1	C2	C3	C4	C5* 多模态有效能力	综合得分	备注
1	GPT-5.6 Sol	80.618	59.358	54.028	73.955	100.000	80.498	
2	Claude Fable 5	48.008	100.000	51.063	100.000	61.411	70.822	
3	Kimi K3	80.222	46.257	66.362	93.780	34.569	53.720	
4	Gemini-3.1-Pro	95.972	41.062	0.000	52.657	59.505	52.276	
5	Qwen3.8-Max	62.030	11.369	44.436	62.073	55.082	46.595	
6	GPT-5.5	88.998	36.467	57.731	38.556	6.974	33.485	
7	Claude Opus 4.8	100.000	45.610	40.819	45.032	0.000	32.456	
8	DeepSeek-V4-Pro	37.365	0.000	100.000	93.163	0*	28.142	Type A
9	GLM-5.2	29.305	9.804	51.063	24.138	0*	14.906	Type A
10	DeepSeek-V4-Flash	0.000	16.616	49.619	0.000	0*	9.504	Type A

注: * 表示模型不具备本题定义的原生多模态能力, 综合能力可用性记为 0; 该值不是 MMMU-Pro、MathVision 等原始测试成绩。

4.7.2 Ranking B: C1–C4 共同能力评价

Ranking B 排除 C5 差异，使用十个模型共同可比较的 C1–C4 并重新计算四维权重。排名前三为 Claude Fable 5 (79.577)、Kimi K3 (67.475) 和 GPT-5.6 Sol (65.990)。因此 Kimi 在共同文本、推理、知识、长上下文和代码能力评价中列第二，说明其第三名主要由 C5* 的综合修正拉低，而不是 C1–C4 的整体竞争力不足。

4.7.3 Ranking C: 具有可估计 C5 能力的多模态模型子集评价

Ranking C 正式名称为“具有可估计 C5 能力的多模态模型子集评价”，对象为七个能够估计 C5 latent ability 的模型。该榜单不意味着所有多模态 Benchmark 均有直接观测，因为其中部分模型仍存在单项 C5 Benchmark 缺失。Ranking C 的前三仍为 GPT-5.6 Sol (77.430)、Claude Fable 5 (67.172) 和 Kimi K3 (50.155)。Ranking A 与 Ranking C 在七个共同模型上的 Spearman 相关为 0.964，表明 C5* 修正没有改变该子集的前三结构。

4.8 模型稳健性与敏感性分析

4.8.1 Bootstrap

采用 $B = 2000$ 次参数 Bootstrap。重采样单位为固定 Benchmark 集合、来源结构和能力适用性条件下的成对比较结果；每次重新拟合五个维度的 BT，并重新计算信息量与非冗余度，潜在排序稳定度 T_d 固定以避免嵌套 Bootstrap。95% 区间为经验百分位区间；网络结构在固定边集下保持不变，BT 不收敛时不丢弃而直接使运行失败。Kimi 在 Ranking A 中的得分区间为 [17.012, 81.843]，排名区间为 [1, 10]，进入前三的经验频率为 0.4225。这里的频率只表示“在本文既定 Benchmark 集合、来源结构及能力适用性条件下”的经验频率，不证明 Kimi 必然稳定第三。




图 5: Ranking A 综合得分及 Bootstrap 95% 区间。

4.8.2 LOFO 与 LOSO

LOFO 检验单个 Benchmark Family 的影响，LOSO 检验单一来源集中度的影响。删除 AA-LCR、Humanity’s Last Exam、LiveBench Coding、MathVision 或 MMMU-Pro 后比较网络不连通，说明这些公开测试在当前网络中具有结构桥接作用，而非程序失败。在其余有效 LOFO 情景中，Kimi 名次为

3-4；删除 LiveBench Logic 或 FrontierSWE 时名次为 4，其余多数有效情景保持第三。LOSO 中删除 LiveBench、Artificial Analysis 或 Kimi 官方来源会导致网络不连通；删除 DeepSeek technical report 或 OpenRouter 后网络仍连通，Kimi 均为第三。




图 6: LOFO 模型排名变化与网络可识别性。

4.8.3 等权敏感性

以各维度等权替代客观权重，Ranking A 与主模型的 Spearman 相关为 0.964、Kendall 相关为 0.911，Kimi 仍列第三且前三集合完全一致；Ranking B 中 Kimi 仍列第二。由此可见，Kimi 的主要结论不依赖某一个小数位的权重设定，但 C5 的结构修正会改变其相对综合分数。

4.9 Kimi K3 竞争优势与短板

以 Kimi 在维度 d 上的得分减去相应比较组中位数定义差值 Δ_d 。C4 的差值为 +36.415，属于具有直接 Benchmark 支撑的强证据优势，可视为 Kimi 的主要竞争优势。C3 的差值为正，但在当前 AA-LCR 公开结果及 C3 比较网络下，Kimi K3 的长上下文潜在能力估计高于样本中位水平，但其 CorpusQA 1M 和 MRCR 1M 缺少直接观测，因此该结论属于模型推断优势，直接证据强度低于 C4。C5 与七个可估计 C5 能力模型的中位数相比为 -20.513，是主要相对短板；该差值没有混入三款结构性能力缺位模型的 0*。

综合来看，Kimi K3 在 Ranking A/B/C 中分别为第 3、2、3 名。其 C4 优势足以支撑较高的共同能力排名，但多模态有效能力较弱使统一综合评价分数降至 53.720。Ranking A 与 Ranking B 的十模型秩相关为 0.818，说明将 C5* 纳入统一体系确实改变了部分中后段次序；而 Ranking A 与 Ranking C 在七个共同模型上的相关性较高，说明该修正的主要作用是对能力适用性进行诚实表达，而不是制造额外的排序波动。

4.10 本问小结

本文针对 Benchmark 不可直接加总、同类指标存在冗余以及缺失性质不一致三个问题，建立了基于同设置成对比较、Family balancing、Margin weighting 和正则化 Bradley-Terry 的三维能力评价方法，并以信息量、非冗余度和潜在排序稳定度确定客观权重。经能力适用性核验，DeepSeek-V4-Pro Max、DeepSeek-V4-Flash Max 和 GLM-5.2 均不具备本题定义的原生多模态能力，三者的 C5* 可用性记为 0，但原始 Benchmark 数据保持缺失。




图 7: Kimi K3 相对于比较组中位能力的差值。

计算结果表明，GPT-5.6 Sol、Claude Fable 5 和 Kimi K3 位居 Ranking A 前三；Kimi 在共同 C1–C4 评价中列第二，在具有可估计 C5 能力的多模态子集中列第三。C4 是 Kimi 的强证据优势，C3 结论需要谨慎解释，C5 是主要短板。Bootstrap、LOFO、LOSO 和等权敏感性共同表明，结论应限定在本文既定 Benchmark 集合、来源结构和能力适用性条件下；对局部指标和相邻名次差异不作超出证据范围的外推。