

从基础能力到部署决策： 大语言模型的缺失感知评价、场景效用与成本约束选型

摘要

针对公开 Benchmark 存在量纲不一致、同类指标冗余和非随机缺失的问题，本文构建了一条由“能力评价—场景效用—部署成本”组成的统一决策链。问题一在 10 个模型、21 个 Exact Setting 和 14 个 Benchmark Family 上，先进行缺失结构审计，再采用缺失感知 Spearman、Family 平衡成对比较和正则化 Bradley-Terry 模型估计复杂推理、知识事实、长上下文、代码工程和多模态多维潜在能力，并以信息量、非冗余度和潜在排序稳定性确定综合权重。Ranking A 中 GPT-5.6 Sol、Claude Fable 5 和 Kimi K3 分列前三，得分分别为 80.5、70.8 和 53.7；有效观测覆盖率为 $164/210 = 78.1\%$ 。问题二将多维能力映射为科研、日常和代码三类任务效用，使用 CES 聚合刻画能力权重与互补关系，结果显示综合排名与场景排名并不等价：科研场景由 Claude Fable 5 居首，代码场景由 Kimi K3 居首。问题三进一步引入输入/输出 Token 工作负载成本，在 8 个 FULL 成本队列模型上构造效用—成本 Pareto 前沿；代码场景的前沿依次经过 DeepSeek-V4-Flash、DeepSeek-V4-Pro 和 Kimi K3，标准任务成本分别为 0.01056、0.03168 和 0.10683 USD。由此，模型选择不应归结为单一总分，而应根据任务能力需求和预算约束在 Pareto 前沿上进行场景化决策。

关键词：大语言模型；Bradley-Terry；CES；缺失感知；Bootstrap；Pareto 前沿；成本约束

1 问题重述

本文研究的对象是公开信息条件下的主流大语言模型。由于不同模型的公开测评覆盖、能力边界和 API 计价方式并不相同，单纯依据某一榜单或一个综合分数进行选择，会把“测得到什么”“任务需要什么”和“部署要花多少”混在一起。本文将三个问题组织为一条递进链：

公开 Benchmark → 基础能力评价 → 场景效用 → 任务成本 → Pareto 决策。

问题一回答“模型本身有多强”。其输入是经过来源、设置和缺失结构审计的 Benchmark 矩阵，输出是五维能力向量与 Ranking A 综合得分。问题二回答“不同任务真正需要什么能力组合”，将问题一的五维能力作为输入，利用场景权重和 CES 替代弹性得到科研、日常和代码三类效用。问题三回答“在性能满足需求的情况下实际部署谁更划算”，把问题二的场景效用与标准化工作负载成本联合起来，得到按场景划分的 Pareto 前沿、预算切换点和稳健性判断。

本文的目标不是建立一个脱离任务的“唯一最佳模型”，而是在保持冻结数据和正式模型结果不变的前提下，给出可追溯、可解释、可复核的模型选择框架。

2 问题分析

2.1 总体思路

公开 Benchmark 的原始分数不具有统一的可加性。不同测试的满分、样本、协议和来源不同；同一能力维度内还可能存在高度相关的 Exact Setting。与此同时，缺失不是普通的随机空白：模型

没有某项能力、供应商没有公开某项成绩以及来源快照尚未覆盖，分别对应不同的数据语义。因此，问题一采用“先审计、后比较、再聚合”的顺序。

问题一得到的五维能力向量描述的是模型的基础能力结构，但 Ranking A 的综合权重只代表总体评价视角。科研长文本分析更依赖长上下文与事实可靠性，代码开发更依赖代码工程能力，日常任务则可能需要知识、推理和多模态可用性的不同组合。因此，问题二不再重复排名，而是把能力向量映射到场景效用。

场景效用仍然不能直接替代部署决策。输入长度、输出长度、调用次数和模型价格共同决定实际成本；当任务规模扩大时，输入/输出单价差异会累积放大。问题三因此保留问题二的效用定义，只增加成本维度，在“效用最大、成本最小”的双目标下识别 Pareto 有效模型。

2.2 信息流与接口

Q1 到 Q2 的接口是模型级五维能力得分和正则化 Bradley-Terry 潜在能力。Q2 到 Q3 的接口是冻结的 30 行场景效用表以及 2,000 个对齐的 Q2 utility draws。它们不是原始 Q1 联合 Bootstrap 重采样，而是由 Q1 点估计和维度级 Bootstrap 标准差做独立正态近似后，再按同一 bootstrap_id 对齐得到的场景不确定性样本。Q3 不重新加权能力，不把 Q1 综合分数替换成性能变量，也不以价格反向修改效用。该接口约束保证三个问题的结论可以沿同一模型身份和同一场景编码追溯。




图 1 全文建模框架：从公开 Benchmark 的缺失与冗余审计，经 Family-balanced Bradley-Terry 能力估计和 Ranking A，到 KL 场景投影、CES 效用、工作负载成本与预算约束下的 Pareto 选择。

3 模型假设与符号

3.1 模型假设

- (1) 每个 Benchmark/Exact Setting 内的公开分数可以用于模型间相对比较，但不同 Benchmark/Exact Setting 的原始分数不直接相加。
- (2) 缺失值保持缺失。结构性能力缺位只在综合能力可用性层单独编码，不将其解释为原始 Benchmark 得分为零。
- (3) Benchmark Family 内部的多个 Exact Setting 可能重复表达同一能力，因此在成对比较阶段进行 Family 平衡。
- (4) Q2 的场景效用只用于同一场景内比较；不同场景的效用尺度不作跨场景绝对比较。
- (5) Q3 的工作负载是用于模型间可比性的标准化任务包，不等同于任意真实用户的平均调用量。

- (6) Q3 主 Pareto 分析只使用成本完整且人工核验通过的 FULL cohort；价格缺失或配置账单不完整的模型不进行插补。

3.2 主要符号

符号	含义
i, j	模型索引
b	Benchmark/Exact Setting 索引
s	场景索引, 取 Research、General、Coding
d	能力维度索引, C_1 – C_5
x_{ib}	模型 i 在 Exact Setting b 上的公开分数
θ_{id}	模型 i 在能力维度 d 上的 BT 潜在能力
S_{id}	由 θ_{id} 转换得到的 0–100 维度得分
w_d	Q1 综合评价权重; $w_d(s)$ 为 Q2 场景权重
$U_i^{(s)}$	模型 i 在场景 s 下的 CES 效用
$C_i^{(s)}$	模型 i 在场景 s 下的标准任务成本
$N_s, L_{in}^{(s)}, L_{out}^{(s)}$	场景调用次数、输入 Token 数和输出 Token 数

4 问题一：缺失感知的五维能力评价

4.1 数据预处理与缺失结构

冻结数据包含 10 个模型、21 个 Exact Setting、14 个 Benchmark Family，理论模型–设置组合为 210 个，其中 164 个为有效观测，覆盖率为

$$\eta = \frac{164}{10 \times 21} = 0.780952.$$

图 2 给出模型–Benchmark 覆盖矩阵。浅色单元格表示 ‘NA’，深色单元格表示 observed；该表示不把缺失压缩成低分。




图 2 Q1 数据覆盖矩阵。缺失值以单独颜色编码，不转换为 0。

五个能力维度定义为: C_1 复杂推理, C_2 知识与事实可靠性, C_3 长上下文, C_4 代码与软件工程, C_5 多模态。对于 C_5 , 先核验模型是否具备本题定义的原生多模态能力, 再判断具体 Benchmark

是否有公开结果。DeepSeek-V4-Pro、DeepSeek-V4-Flash 和 GLM-5.2 的 C5 原始单元保持 ‘NA’，只在综合能力可用性层记录结构性缺位；因此“可用性为 0”不等于“原始测试得分为 0”。

4.2 Missing-aware Spearman 与 Family 平衡

对两个 Exact Setting a, b ，在共同有效模型集合

$$I_{ab} = \{i : x_{ia} \text{ 和 } x_{ib} \text{ 均有效}\}$$

上计算 Spearman 秩相关 [2] ρ_{ab} 。图 3 显示，部分 Benchmark 对存在较高相关，但相关性只作为冗余候选证据；当共同样本较小或该设置承担比较网络桥接作用时，不机械删除，而保留并在 LOFO 中检验。




图 3 缺失感知 Spearman 相关矩阵。颜色表示共同有效模型上的秩相关；上三角数字表示对应设置的 Common-N。

对于同一 Benchmark/Exact Setting b 上的模型对 (i, j) ，定义

$$y_{ijb} = \begin{cases} 1, & x_{ib} > x_{jb}, \\ 0.5, & x_{ib} = x_{jb}, \\ 0, & x_{ib} < x_{jb}. \end{cases}$$

任一模型缺失该设置时不构造成对关系。为了保留领先幅度，按同一设置内的相对差值构造 margin

权重,再在每个能力维度内对 Family 和 Setting 分层归一化,使一个 Family 含有更多 Exact Setting 时不会自动获得更高权重。

4.3 正则化 Bradley–Terry 能力估计

令 θ_{id} 为模型 i 在维度 d 上的潜在能力,则采用 Bradley–Terry 成对比较模型 [1]

$$P(i \succ j) = \frac{\exp(\theta_{id})}{\exp(\theta_{id}) + \exp(\theta_{jd})}.$$

在全部有效成对比较上,求解带 L_2 正则项且满足 $\sum_i \theta_{id} = 0$ 的加权极大似然:

$$\hat{\theta}_d = \arg \min_{\theta} \left\{ - \sum_r \omega_r [y_r \log p_r + (1 - y_r) \log(1 - p_r)] + \frac{\lambda}{2} \sum_i \theta_{id}^2 \right\}, \quad \lambda = 1.$$

各维度均收敛。随后在维度内部将 θ 线性转换为 0–100 的 S_{id} ; 该转换只服务于维度内表达,不把不同 Benchmark 原始分数强行放到同一量纲。

4.4 综合权重与 Ranking A

以维度得分分布的信息量 I_d 、与其他维度的非冗余度 R_d 和潜在排序稳定度 T_d 构造

$$q_d = I_d R_d T_d, \quad w_d = \frac{q_d}{\sum_k q_k}.$$

Ranking A 的权重为

$$(w_{C1}, w_{C2}, w_{C3}, w_{C4}, w_{C5}) = (0.1282, 0.2034, 0.1234, 0.1182, 0.4268).$$

C5 权重较高的原因不是人为偏好,而是其在当前冻结数据下的信息量与排序区分度较强;结构性能力缺位仍与观测缺失严格分开。

4.5 Q1 结果：能力结构与综合评价

图 4 以雷达图展示五维能力结构,并在右侧给出 Ranking A 得分及 Bootstrap 95% 区间。GPT-5.6 Sol 的综合得分为 80.5, Claude Fable 5 为 70.8, Kimi K3 为 53.7, Gemini-3.1-Pro 为 52.3。Kimi 的 C4 得分为 93.8, 是其最强维度; C5 BT 得分为 34.6, 是其相对短板。该结果说明“代码能力强”并不自动等价于“统一综合评价第一”,因为 Ranking A 同时考虑五个维度和 C5 可用性。

表 1 Ranking A 主要结果

排名	模型	综合得分	95% CI 下界	95% CI 上界
1	GPT-5.6 Sol	80.5	19.5	84.4
2	Claude Fable 5	70.8	20.0	86.0
3	Kimi K3	53.7	17.0	81.8
4	Gemini-3.1-Pro	52.3	17.1	80.1
5	Qwen3.8-Max	46.6	19.4	76.2




图 4 各模型五维能力结构与 Ranking A 综合得分。雷达图对结构性缺失保留空缺，不将原始 NA 绘制为 0；右图区间来自正式 Bootstrap 输出。

4.6 稳健性分析

图 5 给出 Ranking A 的 Bootstrap 排名概率。Kimi 的进入前三经验频率仅为 0.4225，排名区间为 [1, 10]；该区间反映冻结 Benchmark 集合与模型不确定性传播下的经验波动，不应解读为真实市场排名的概率预测。




图 5 Ranking A 的 Bootstrap 排名概率热图。

LOFO 结果如图 6 所示。在有效删除情景中，完整 Ranking A 与删除单个 Benchmark 后的 Spearman 相关大多保持在 0.94 以上；若删除某些桥接设置，比较网络会断开，此时不把不连通结果强行转化为排名。LOFO 只说明总体排序对单一 Benchmark 删除较稳健，不代表 Bootstrap 下头部具体名次稳定。结合 Bootstrap 中 Kimi 进入前三的频率为 0.4225 且排名区间为 [1, 10]，头部名次仍存在明显不确定性。




图 6 LOFO 稳健性：删除单个 Benchmark 后与完整 Ranking A 的秩相关；× 表示 comparison network disconnected。

5 问题二：考虑能力互补的场景效用

5.1 从基础能力到场景效用

问题一的五维能力向量描述“模型有什么能力”，但不同任务对能力的需求权重不同，且能力之间可能存在互补关系。因此，问题二以问题一的潜在能力作为输入，不再使用 Ranking A 的固定权重，而是为每个场景设置 $w_j(s)$ 和 CES 替代弹性 ρ_s 。

设 Q1 的归一化权重先验为 $\bar{w}^{Q1}$ 。对每个场景 s ，在冻结的场景约束集 $\mathcal{C}_s$ 上求

$$w^{(s)} = \arg \min_w D_{\text{KL}}(w \| \bar{w}^{Q1}), \quad \sum_d w_d = 1, \quad w_d \geq 0, \quad w \in \mathcal{C}_s.$$

其中 $\mathcal{C}_R = \{C1, C2, C3\}$ 、 $\mathcal{C}_G = \{C1, C2, C3, C5\}$ 、 $\mathcal{C}_C = \{C1, C4\}$ ；也就是说，Research、General、Coding 分别只允许在上述能力子集上分配权重，其余维度权重固定为 0。冻结接口给出的最优解正是下面三组数值，因此它们不是人工重打分，而是对 Q1 先验在各自可行域内做 I-projection 后得到的唯一场景权重。

先将每一维潜在能力转化为同维度内的正值；CES 聚合沿用常数替代弹性框架 [3]

$$z_{ij} = \exp(\theta_{ij} - \max_i \theta_{ij}),$$

再定义

$$U_i^{(s)} = \begin{cases} \left[\sum_{j \in J_s} w_j(s) (z_{ij} + \varepsilon)^{\rho_s} \right]^{1/\rho_s}, & \rho_s \neq 0, \\ \exp\left(\sum_{j \in J_s} w_j(s) \ln(z_{ij} + \varepsilon) \right), & \rho_s = 0, \end{cases} \quad \varepsilon = 10^{-6}.$$

当 $\rho_s \rightarrow 0$ 时，上式连续收敛为加权几何平均。 $\rho_s < 0$ 表示短板会显著拖累效用，适合表达科研长文本和代码任务中关键能力之间的互补约束。

5.2 场景需求与参数

冻结接口给出的场景需求如图 7 所示。科研场景的权重为

$$(w_{C1}, w_{C2}, w_{C3}) = (0.3439, 0.3250, 0.3311), \quad \rho = -0.50.$$

日常场景的权重为

$$(w_{C1}, w_{C2}, w_{C3}, w_{C5}) = (0.2417, 0.3833, 0.1000, 0.2750), \quad \rho = 0.$$

代码场景的权重为 $(w_{C1}, w_{C4}) = (0.3500, 0.6500)$, $\rho = -0.40$ 。这些权重是对 Q1 客观权重先验进行 KL 最小信息投影后的场景约束结果，不是重新主观打分。




图 7 三类场景的能力需求权重。空白维度表示不属于该场景的冻结支持集。




图 8 三类场景的 CES 效用比较。每个面板只在对应场景内比较效用大小。

5.3 场景效用结果与排名迁移

科研场景中 Claude Fable 5、Kimi K3 和 GPT-5.6 Sol 位列前三，效用分别为 0.918、0.901 和 0.899；日常场景中 Claude Fable 5 与 GPT-5.6 Sol 几乎并列第一，效用分别为 0.932 和 0.932；代码场景中 Kimi K3 以 0.981 居首，Claude Fable 5 和 DeepSeek-V4-Pro 分列第二、三位。不同场景的绝对效用不作跨场景比较，但场景内排名可直接用于解释能力组合的变化。

图 9把 Q1 综合排名、科研、日常和代码排名放在同一张 slopegraph 中。Q1 综合第一的 GPT-5.6 Sol 在科研场景降至第三，在代码场景降至第四；Kimi K3 则由综合第三升至代码第一。这不是排序算法失稳，而是场景权重把 C4 的高水平显式传递到代码效用中。




图 9 综合排名到场景排名的迁移。排名 1 为最好。

5.4 CES 敏感性

图 10在保持冻结场景权重不变的条件下改变 ρ ，用于检查名义替代弹性附近的相对关系。科研场景的名义值为 -0.50 ，代码场景为 -0.40 ；图中虚线处的点与冻结 Q2 名义效用逐点对齐。测试网格内，Kimi 的代码效用优势并不依赖单一的精确参数点，GPT-5.6 Sol 和 Claude Fable 5 的科研相对位置也没有发生结构性反转。该敏感性只检验 CES 聚合对参数设定的响应，不替代正式 Q2 的冻结名义结果。




图 10 CES 替代弹性敏感性。虚线表示冻结名义 ρ ，交点与冻结 Q2 名义效用一致。

6 问题三：成本约束下的 Pareto 决策

6.1 从场景效用到部署成本

场景效用只能回答模型是否适合某类任务，不能回答在预算约束下是否值得使用。问题三沿用问题二的 $U_i^{(s)}$ ，不重新构造性能指标，只增加由工作负载和价格共同决定的成本。

设模型 i 的输入、输出单价分别为 $p_{\text{in},i}$ 和 $p_{\text{out},i}$ ，场景 s 的调用次数、计费输入 Token、计费输出 Token 分别为 $N_s, L_{\text{in}}^{(s)}, L_{\text{out}}^{(s)}$ 。冻结价格单位为 USD/1M billable tokens，因此

$$C_i^{(s)} = \frac{N_s}{10^6} \left[L_{\text{in}}^{(s)} p_{\text{in},i} + L_{\text{out}}^{(s)} p_{\text{out},i} \right].$$

输出 Token 包括供应商计费规则下的 reasoning/thinking Token，而不只包含用户可见文本。

表 2 Q3 标准化基准工作负载

场景	N_s	L_{in}	L_{out}	$L_{\text{out}}/L_{\text{in}}$
科研	1	16000	4000	0.25
日常	1	2000	1000	0.50
代码	1	6000	6000	1.00

6.2 成本可观测性与主分析队列

Q3 冻结结果将模型分为 8 个 FULL、1 个 PARTIAL 和 1 个 MISSING。Claude Fable 5 的基础 SKU 单价可见，但 max-with-fallback 配置缺少完整的 fallback 目标与二次计费轨迹；GLM-5.2 缺少可复核的公开标准 input/output API 单价。二者保留在成本审计表中，但不进入严格主 Pareto。该处理避免把价格缺失误读为零成本，也避免用邻近模型或人工补价制造完整队列。动态价格记录保留供应商来源、冻结日期、API SKU 与评测配置；完整记录见附录表 5。




图 11 代码场景 FULL 队列的输入/输出成本构成。

6.3 Pareto 定义与场景结果

在同一场景内，若模型 a 满足以下 Pareto 支配关系 [4]

$$U_a^{(s)} \geq U_b^{(s)}, \quad C_a^{(s)} \leq C_b^{(s)}$$

且至少一项严格不等，则称 a 支配 b 。未被任何模型支配的模型构成 Pareto 前沿。

图 12 显示三个场景的效用—成本前沿。科研场景的前沿为 DeepSeek-V4-Flash、DeepSeek-V4-Pro 和 Kimi K3；日常场景的前沿扩大到 6 个模型，包括 GPT-5.6 Sol；代码场景前沿为 DeepSeek-V4-Flash、DeepSeek-V4-Pro 和 Kimi K3。代码场景中，DeepSeek-V4-Pro 以 0.03168 USD 获得 0.9611 效用，Kimi K3 以 0.10683 USD 获得 0.9813 效用，二者分别代表“低成本的高效用节点”和“更高效用的高成本节点”。




图 12 科研、日常和代码场景的效用—成本 Pareto 前沿。

6.4 预算切换

在固定标准工作负载下，预算约束可以直接转化为“最优可行模型”的切换规则。图 13 从冻结预算切换点重建三类场景的决策阶梯；横轴是预算上限，纵轴是满足预算且效用最高的模型。




图 13 预算增加时的最优可行模型切换。科研、日常、代码的 panel 顺序与正文一致；竖线标注冻结预算切换点。

以代码场景为例，冻结结果给出的三个切换阈值依次为 0.01056、0.03168 和 0.10683 USD：预算低于首个阈值时没有可行模型，达到首个阈值后选择 DeepSeek-V4-Flash，达到第二个阈值后切

换到 DeepSeek-V4-Pro，达到第三个阈值后才切换到 Kimi K3。Q3 冻结敏感性分析保留 nominal Pareto 成员，说明这些前沿节点在测试范围内具有稳定的决策含义。

7 模型评价与改进

7.1 模型优点

- (1) **数据语义清晰。**观测、普通缺失和结构性能力缺位分别处理；原始 NA 不被改写为 0，价格缺失不被人工补齐。
- (2) **跨问题接口明确。**Q1 输出多维能力，Q2 输出场景效用，Q3 直接读取冻结效用并增加工作负载成本，避免同一模型在不同问题中使用不同身份或不同性能定义。
- (3) **稳健性证据完整。**Q1 同时提供 Bootstrap、LOFO、LOSO 和等权敏感性；Q3 对成本观测性、Pareto 前沿和预算切换进行独立审计。
- (4) **决策含义具体。**综合排名、场景排名和成本前沿分别回答不同问题，读者可以根据任务类型和预算选择节点，而不是接受一个脱离约束的总榜。


7.2 局限与改进方向

第一，公开 Benchmark 仍然是横截面快照，不能完全替代统一实验环境；第二，Q1 的潜在能力估计依赖可观测比较网络，桥接设置缺失时可能导致网络不连通；第三，Q2 的不确定性传播采用独立正态近似生成的 2,000 个对齐 utility draws，而不是原始 Q1 联合 Bootstrap；第四，Q3 使用标准化工作负载，价格也可能随时间变化；第五，Fable fallback 和 GLM 公共价格仍未达到完整成本可观测性。后续可引入统一测评、联合 Bootstrap 协方差、时间序列价格和用户真实 Token 分布，并将延迟、吞吐、安全与工具可用性纳入多目标决策。

8 结论

本文将 Q1、Q2、Q3 组织为一个连续的数学决策框架。Q1 在 78.1% 的有效 Benchmark 覆盖下，通过缺失感知相关性、Family 平衡成对比较和正则化 Bradley–Terry 得到多维能力结构；Ranking A 中 GPT-5.6 Sol、Claude Fable 5 和 Kimi K3 位居前三。Q2 说明综合能力并不等于具体任务效用：科研场景由 Claude Fable 5 居首，代码场景由 Kimi K3 居首。Q3 进一步表明，性能优势只有在成本可观测且预算允许时才转化为部署选择；代码场景的 Pareto 前沿从 DeepSeek-V4-Flash 延伸到 DeepSeek-V4-Pro 和 Kimi K3。

因此，本文的最终结论不是“某一个模型永远最好”，而是：



这条链条将模型评价从单一排名推进到基于能力、任务和预算的可追溯决策。

参考文献

[1] Bradley R A, Terry M E. Rank analysis of incomplete block designs: I. The method of paired comparisons[J]. *Biometrika*, 1952, 39(3–4): 324–345.

- [2] Spearman C. The proof and measurement of association between two things[J]. *The American Journal of Psychology*, 1904, 15(1): 72–101.
- [3] Arrow K J, Chenery H B, Minhas B S, Solow R M. Capital-labor substitution and economic efficiency[J]. *The Review of Economics and Statistics*, 1961, 43(3): 225–250.
- [4] Pareto V. *Manuale di economia politica*[M]. Milano: Società Editrice Libreria, 1906.
- [5] Rein D, Hou B L, Stickland A C, et al. GPQA: A graduate-level Google-proof Q&A benchmark[EB/OL]. Official benchmark repository: <https://github.com/idavidrein/gpqa>.
- [6] LiveBench. LiveBench official benchmark site[EB/OL]. <https://livebench.ai/>.
- [7] Center for AI Safety. Humanity’s Last Exam official repository[EB/OL]. <https://github.com/centerforaisafety/hle>.
- [8] Yue X, Ni Y, Zhang K, et al. MMMU-Pro official benchmark repository[EB/OL]. <https://github.com/MMMU-Benchmark/MMMU>.
- [9] MathVision official benchmark repository[EB/OL]. <https://github.com/mathvision-cuhk/MathVision>.
- [10] OpenAI. GPT-5.5 and GPT-5.6 Sol model documentation and API pricing[EB/OL]. Snapshot recorded in the frozen Q3 pricing audit on 2026-08-17. <https://developers.openai.com/api/docs/models/gpt-5.6-sol>.
- [11] Anthropic. Claude model documentation and API pricing[EB/OL]. Snapshot recorded in the frozen Q3 pricing audit on 2026-08-17. <https://docs.anthropic.com/en/docs/about-claude/pricing>.
- [12] Google DeepMind. Gemini API model documentation and pricing[EB/OL]. Snapshot recorded in the frozen Q3 pricing audit on 2026-08-17. <https://ai.google.dev/gemini-api/docs/pricing>.
- [13] DeepSeek. API model documentation and pricing[EB/OL]. Snapshot recorded in the frozen Q3 pricing audit on 2026-08-17. https://api-docs.deepseek.com/quick_start/pricing.
- [14] Moonshot AI. Kimi K3 official model documentation and pricing[EB/OL]. Snapshot recorded in the frozen Q3 pricing audit on 2026-08-17. <https://platform.kimi.com/docs/pricing/chat-k3.md>.
- [15] Alibaba Cloud. Qwen model studio pricing documentation[EB/OL]. Snapshot recorded in the frozen Q3 pricing audit on 2026-08-17. <https://help.aliyun.com/zh/model-studio/model-pricing>.
- [16] Zhipu AI. GLM-5.2 model documentation[EB/OL]. Snapshot recorded in the frozen Q3 pricing audit on 2026-08-17. <https://docs.bigmodel.cn/cn/guide/models/text/glm-5.2.md>.

A 补充稳健性与价格快照

A.1 LOSO 稳健性

LOSO 结果直接读取 Q1 正式输出。有效比较保留共同模型数、与完整 Ranking A 的 Spearman 相关、Kimi 的其他排名和前三重叠数；比较网络断开时以 × 标记，不将其填充为数值。

表 3 LOSO 场景/来源删除审计。数据源：outputs/q1_v1.2/tables/table_q1_v12_loso.xlsx, sheet Scenario_Summary。

删除对象	Common-N	Spearman	Kimi 其他排名	Top-3 重叠	状态
LiveBench	×	—	—	—	—
Artificial Analysis	×	—	—	—	—
Kimi official/technical comparison	×	—	—	—	—
DeepSeek technical report	10	1.000	3	3	OK
OpenRouter	10	0.988	3	3	OK

A.2 等权敏感性

将 Q1 综合权重替换为五维等权后，Ranking A 前三模型及其顺序保持不变；完整十模型的名次变化见表 4。该表只报告正式等权敏感性输出，不重新估计任何分数。

表 4 等权敏感性的逐模型比较。

完整排名	模型	等权排名	名次变化	原得分	等权得分
1	GPT-5.6 Sol	1	0	80.5	73.6
2	Claude Fable 5	2	0	70.8	72.1
3	Kimi K3	3	0	53.7	64.2
4	Gemini-3.1-Pro	4	0	52.3	49.8
5	Qwen3.8-Max	5	0	46.6	47.0
6	GPT-5.5	8	+2	33.5	45.7
7	Claude Opus 4.8	6	-1	32.5	46.3
8	DeepSeek-V4-Pro	7	-1	28.1	46.1
9	GLM-5.2	9	0	14.9	22.9
10	DeepSeek-V4-Flash	10	0	9.5	13.2

A.3 动态价格记录

价格只用于 Q3 成本审计，冻结快照日期、API SKU、评测配置和供应商官方来源均保留在表 5。其中 SPECIAL_CASE 和缺失价格不会被视为零成本，也不进入严格 FULL 主 Pareto。

表 5 Q3 动态价格快照与 SKU/configuration 记录。数据源: q3/frozen/v1.0/model_pricing.csv; price_date 为冻结/快照日期。

模型	快照日期	SKU / exact configuration	官方来源
Kimi K3 (max reasoning)	2026-08-17	kimi-k3 reasoning_effort=max / kimi-k3	official
GPT-5.6 Sol (max)	2026-08-17	gpt-5.6-sol reasoning.effort=max / gpt-5.6-sol	official
GPT-5.5 (xhigh)	2026-08-17	gpt-5.5 reasoning.effort=xhigh / gpt-5.5	official
Claude Fable 5 (max, with fallback)	2026-08-17	claude-fable-5 base model with benchmark fallback / claude-fable-5	official
Claude Opus 4.8 (max)	2026-08-17	claude-opus-4-8 effort=max / claude-opus-4-8	official
Gemini-3.1-Pro (High)	2026-08-17	gemini-3.1-pro-preview thinking_level=high / gemini-3.1-pro-preview	official
DeepSeek-V4-Pro Max	2026-08-17	DeepSeek-V4-Pro-0813 thinking mode / deepseek-v4-pro	official
DeepSeek-V4-Flash Max	2026-08-17	DeepSeek-V4-Flash-0731 thinking mode / deepseek-v4-flash	official
Qwen3.8-Max	2026-08-17	qwen3.8-max thinking or non-thinking mode / qwen3.8-max	official
GLM-5.2 (max)	2026-08-17	glm-5.2 reasoning_effort=max / glm-5.2	official