

问题三：成本约束下的大模型场景化选型

说明：本文仅使用 Q3 v1.0 冻结数据与冻结结果，供竞赛论文整合前人工审阅。

1 问题分析

问题二已经根据不同任务对能力维度的需求差异，得到模型在 Research、General 和 Coding 三类场景下的综合效用，记为 $U_i^{(s)}$ 。问题三不重新构造性能评分，而是在沿用该场景效用的基础上，进一步引入实际 API 调用成本，从“适配性评价”转向经济约束下的模型选择。

直接使用传统的

$$E_i = \frac{P_i}{C_i}$$

难以准确描述本题。一方面，API 通常分别按照输入 Token 和输出 Token 计价，输入单价与输出单价对总费用的贡献并不相同；另一方面，科研长文本、日常问答和代码生成在输入长度与输出长度上的比例不同。因此，成本不是模型自身的固定属性，而应写成工作负载的函数 $C_i = C_i(W_s)$ 。由此，问题三自然形成如下双目标决策：

$$\max U_i^{(s)}, \quad \min C_i^{(s)}$$

其中，模型效用来自问题二，成本由模型价格与场景工作负载共同决定。

本研究的严格主分析只使用完整成本可观测且已人工核验的 FULL cohort。Claude Fable 5 的基础 SKU 单价可获得，但评测配置包含 fallback，缺乏完整的 fallback 目标模型和二次 Token 计费轨迹，因此完整配置成本无法严格复原。GLM-5.2 的模型及推理配置能够确认，但在价格采集时点缺少可复核的公开标准 input/output API 单价。二者均不进入严格成本-效用 Pareto 比较；这表示成本不可观测，而不表示模型性能较低或成本为零。

2 场景工作负载成本模型

2.1 API 调用成本建模

设 $i \in \mathcal{M}$ 表示模型， $s \in \mathcal{S}$ 表示场景，标准任务包的调用次数为 N_s ，单次平均计费输入和输出 Token 数分别为 $L_{\text{in}}^{(s)}$ 与 $L_{\text{out}}^{(s)}$ ，模型的输入和输出单价分别为 $p_{\text{in},i}$ 与 $p_{\text{out},i}$ 。冻结价格单位为 USD/1M billable tokens，因此场景成本为

$$C_i^{(s)} = \frac{N_s}{10^6} \left[L_{\text{in}}^{(s)} p_{\text{in},i} + L_{\text{out}}^{(s)} p_{\text{out},i} \right]. \quad (1)$$

式中 $L_{\text{out}}^{(s)}$ 表示计费输出 Token 数，而不是仅指用户可见的回答文本长度；对于 reasoning/thinking 模型，若官方计费规则将推理 Token 计入输出计费，则相应 Token 一并计入该项。

表 1: 三类标准化场景工作负载

场景	N_s	$L_{in}^{(s)}$	$L_{out}^{(s)}$	L_{out}/L_{in}	任务含义
Research	1	16000	4000	0.25	科研长文本分析
General	1	2000	1000	0.50	通用日常任务
Coding	1	6000	6000	1.00	代码开发

注：上述设定是用于模型间可比性的标准化典型工作负载，不等同于行业真实平均调用量。

2.2 成本数据可观测性处理

将模型集合按完整成本的可观测程度划分为 $\mathcal{M}_{full}$ 、 $\mathcal{M}_{partial}$ 和 $\mathcal{M}_{missing}$ 。Q3 的严格主分析采用 $\mathcal{M}_{full}$ ，不对缺失价格进行均值填补、邻近模型替代或人为估算。冻结结果中，主分析 cohort 包含 8 个 FULL 模型，PARTIAL 为 Claude Fable 5，MISSING 为 GLM-5.2。

表 2: FULL 主分析模型及冻结 API 单价

模型	输入单价	输出单价	Research 成本	General 成本	Coding 成本
Claude Opus 4.8	5.0000	25.0000	0.180000	0.035000	0.180000
DeepSeek-V4-Flash Max	0.4400	1.3200	0.012320	0.002200	0.010560
DeepSeek-V4-Pro Max	1.3200	3.9600	0.036960	0.006600	0.031680
Gemini-3.1-Pro (High)	2.0000	12.0000	0.080000	0.016000	0.084000
GPT-5.5	5.0000	30.0000	0.200000	0.040000	0.210000
GPT-5.6 Sol	5.0000	30.0000	0.200000	0.040000	0.210000
Kimi K3	2.9675	14.8375	0.106830	0.020773	0.106830
Qwen3.8-Max	1.7805	5.3415	0.049854	0.008903	0.042732

注：价格和成本单位均为 USD；价格采用冻结记录中的官方 SKU、配置及审计日换算结果。

3 性能–成本双目标决策模型

3.1 Pareto 支配关系

在场景 s 下，若模型 j 满足

$$U_j^{(s)} \geq U_i^{(s)}, \quad C_j^{(s)} \leq C_i^{(s)},$$

且至少一个不等式严格成立，则称 j 支配 i ，记作 $j \succ i$ 。Pareto 有效集合定义为

$$\mathcal{P}_s = \{i \in \mathcal{M}_{full} : \nexists j, j \succ i\}.$$

Pareto 前沿上的模型不能在“不增加成本且不降低效用”的条件下被另一模型完全替代，因此它们代表不同的性能–成本权衡，而不是一个固定的总排名。

3.2 Pareto 前沿结果

图 1 表明，最低成本模型在三个场景中均为 DeepSeek-V4-Flash Max，但前沿结构随场景效用变化而改变。Research 的三个前沿点效用依次为 0.827289、0.877794 和 0.901293，对应成本为 0.012320、0.036960 和 0.106830 USD。Coding 的三个前沿点效用依次为 0.815577、0.961063 和 0.981302，对应成本为 0.010560、0.031680 和 0.106830 USD。

General 场景的前沿更长,依次包含 DeepSeek-V4-Flash Max、DeepSeek-V4-Pro Max、Qwen3.8-Max、Gemini-3.1-Pro (High)、Kimi K3 和 GPT-5.6 Sol。其效用由 0.646876 提升至 0.932145,成本门槛由 0.002200 增至 0.040000 USD。相较之下,Research 和 Coding 中的部分高价模型未带来足以抵消成本的效用优势,因而被 DeepSeek-V4-Pro Max 或 Kimi K3 支配。Fable 与 GLM 是进入严格比较前因成本不可观测而被排除,不应表述为被 Pareto 支配。

4 预算约束下的最优模型选择

给定用户预算 B , 定义场景 s 下的最优可行模型为

$$i^*(B, s) = \arg \max_{i \in \mathcal{M}_{\text{full}}} U_i^{(s)} \quad \text{s.t.} \quad C_i^{(s)} \leq B. \quad (2)$$

预算从低到高变化时, 最优模型在 Pareto 模型的成本门槛处发生离散切换。冻结结果如表 3 所示。

表 3: 三类场景预算约束下的最优模型切换

场景	预算区间 (USD)	最优模型
Research	$0.012320 \leq B < 0.036960$	DeepSeek-V4-Flash Max
Research	$0.036960 \leq B < 0.106830$	DeepSeek-V4-Pro Max
Research	$B \geq 0.106830$	Kimi K3
General	$0.002200 \leq B < 0.006600$	DeepSeek-V4-Flash Max
General	$0.006600 \leq B < 0.008903$	DeepSeek-V4-Pro Max
General	$0.008903 \leq B < 0.016000$	Qwen3.8-Max
General	$0.016000 \leq B < 0.020773$	Gemini-3.1-Pro (High)
General	$0.020773 \leq B < 0.040000$	Kimi K3
General	$B \geq 0.040000$	GPT-5.6 Sol
Coding	$0.010560 \leq B < 0.031680$	DeepSeek-V4-Flash Max
Coding	$0.031680 \leq B < 0.106830$	DeepSeek-V4-Pro Max
Coding	$B \geq 0.106830$	Kimi K3

5 增量成本效益分析

沿各场景 Pareto 前沿按成本升序排列, 对相邻模型定义

$$ICER_k = \frac{C_{k+1} - C_k}{U_{k+1} - U_k}.$$

该指标表示从当前有效模型升级到下一有效模型时, 每增加一单位场景效用所需承担的额外成本, 并不等同于静态“性价比”。

Coding 和 Research 的末端升级分别需要 3.713059 和 2.973325 USD/utility, 显著高于前一段升级。这说明从 DeepSeek-V4-Pro Max 转向 Kimi K3 虽可继续提高效用, 但追加成本相对于效用增益较大。General 的前沿包含更多中间层级: DeepSeek-V4-Pro Max 到 Qwen3.8-Max 的 ICER 仅为 0.012507, 而 Gemini-3.1-Pro (High) 到 Kimi K3 的效用增量只有 0.002548, 对应 1.872844 USD/utility, 表现出明显不同的边际升级特征。




图 1: 三类任务场景下模型效用-成本分布及 Pareto 有效前沿




图 2: 预算增加过程中的最优模型切换

表 4: Pareto 前沿相邻升级的增量成本效益

场景	当前模型	升级模型	ΔC	ΔU	ICER
Coding	DeepSeek Flash	DeepSeek Pro	0.021120	0.145485	0.145169
Coding	DeepSeek Pro	Kimi K3	0.075150	0.020239	3.713059
General	DeepSeek Flash	DeepSeek Pro	0.004400	0.007410	0.593761
General	DeepSeek Pro	Qwen3.8-Max	0.002303	0.184094	0.012507
General	Qwen3.8-Max	Gemini Pro (High)	0.007098	0.027779	0.255499
General	Gemini Pro (High)	Kimi K3	0.004772	0.002548	1.872844
General	Kimi K3	GPT-5.6 Sol	0.019228	0.063438	0.303089
Research	DeepSeek Flash	DeepSeek Pro	0.024640	0.050504	0.487879
Research	DeepSeek Pro	Kimi K3	0.069870	0.023499	2.973325

注: 成本单位为 USD, ICER 单位为 USD/utility。




图 3: 三类场景 Pareto 前沿相邻升级的增量成本效益

6 成本-性能变化规律

为避免仅依赖样本内拟合优度，分别对全体 FULL cohort 和 Pareto 子集比较

$$U = a + bC, \quad U = a + b \ln(1 + C), \quad U = a - be^{-kC}.$$

评价指标包括 R^2 、AIC、AICc、BIC 和留一交叉验证误差 (LOOCV)。全体 FULL cohort 的样本量为 $n = 8$ ，因此 AICc 和 LOOCV 比单独使用 R^2 更重要。

表 5: 全体 FULL cohort 的成本-性能拟合摘要

场景	模型	R^2	AIC	AICc	BIC	LOOCV
Research	Linear	0.470986	-57.794596	-55.394596	-57.635713	0.000682
Research	Log	0.473763	-57.836691	-55.436691	-57.677808	0.000678
Research	Saturation	0.481753	-55.959100	-49.959100	-55.720775	0.000870
General	Linear	0.506858	-39.042970	-36.642970	-38.884087	0.008176
General	Log	0.509852	-39.091699	-36.691699	-38.932816	0.008130
General	Saturation	0.755203	-42.645925	-36.645925	-42.407600	9.802600
Coding	Linear	0.070341	-45.508753	-43.108753	-45.349870	0.004055
Coding	Log	0.077727	-45.572561	-43.172561	-45.413677	0.004089
Coding	Saturation	0.070329	-43.508649	-37.508649	-43.270324	0.003159

按 AICc, Research 和 Coding 的最优候选分别为 Log, General 的最优候选为 Saturation; 按 LOOCV, Research 选择 Log, General 选择 Log, Coding 选择 Saturation。然而 General 的 Saturation LOOCV error 为 9.802600, 远高于 Linear 和 Log, 说明其样本内拟合优势并不具有稳定的外推表现。Research 和 Coding 的 Pareto 前沿只有 3 个点, 前沿拟合因此标记为“前沿样本不足”。综合样本规模、指标差异和前沿样本不足, 当前数据没有提供跨场景统一的成本边际收益递减规律证据。

上述关系来自同一时间截面的模型性能与价格数据, 只反映成本与场景效用之间的统计关联, 不构成成本导致性能提升的因果证据。

7 敏感性与稳健性分析

7.1 工作负载与价格敏感性

Q3 分别改变输入规模、输出/输入比例和价格, 对成本排序、Pareto 成员及预算切换进行检验。对三类场景的全部测试网格, nominal Pareto 成员保留率和“全部 nominal 成员仍被保留”的比例均为 1.0000。输入规模测试点分别为 3 个, 输出/输入比例测试点为 5 个, 价格扰动测试点为 5 个; 价格扰动采用 -10% , -5% , 0 , $+5\%$, $+10\%$ 。

当 $r = L_{\text{out}}/L_{\text{in}}$ 时, 成本可写成

$$C_i^{(s)} = \frac{N_s L_{\text{in}}^{(s)}}{10^6} (p_{\text{in},i} + r p_{\text{out},i}).$$

因此, 任务由输入密集型转向输出密集型时, 模型之间的成本差异会更多受到输出单价影响。冻结敏感性结果显示, 在本次标准化测试网格内, 三类场景的 Pareto 结构均保持稳定; 这一结论不延伸为对未观测生产负载或未来价格变化的无条件保证。

7.2 Bootstrap Pareto 稳定性

Q2 已提供 2000 次 bootstrap 场景效用抽样。对每一次抽样 b ，Q3 在固定 FULL cohort 成本下重新计算 Pareto 集合 $\mathcal{P}_s^{(b)}$ ，定义模型进入前沿的概率为

$$\pi_i^{(s)} = \frac{1}{2000} \sum_{b=1}^{2000} \mathbf{1}(i \in \mathcal{P}_s^{(b)}).$$

该概率刻画能力估计不确定性向 Q3 传播后，模型仍保持 Pareto 有效的频率。

表 6: Bootstrap Pareto 有效概率

模型	Research	General	Coding
Claude Opus 4.8	0.0565	0.0400	0.0015
DeepSeek-V4-Flash Max	1.0000	1.0000	1.0000
DeepSeek-V4-Pro Max	0.8890	0.6745	0.9465
Gemini-3.1-Pro (High)	0.1100	0.9050	0.1620
GPT-5.5	0.0335	0.0000	0.0000
GPT-5.6 Sol	0.3405	0.9765	0.0600
Kimi K3	0.7355	0.5225	0.6150
Qwen3.8-Max	0.1045	1.0000	0.2840

Bootstrap 结果强化了若干 nominal 结论：DeepSeek-V4-Flash Max 在三个场景中的 Pareto 概率均为 1.0000；DeepSeek-V4-Pro Max 在 Coding、General、Research 中分别为 0.9465、0.6745、0.8890。General 场景的 Qwen3.8-Max 和 GPT-5.6 Sol 概率分别为 1.0000 和 0.9765，说明其在该场景下的前沿地位较稳定。Kimi K3 在 Coding 中的概率为 0.6150，在 Research 和 General 中分别为 0.7355 和 0.5225，表现出更明显的边界属性。Bootstrap 概率只传播 Q2 效用估计不确定性，没有覆盖价格更新、缓存、峰谷时段、延迟、可用性或速率限制。

8 问题三结果分析与小结

本题的模型选型不能由一个脱离任务的“性能/价格”比值决定。场景工作负载同时决定输入与输出 Token 的数量，Pareto 分析保留了成本和效用之间的不可替代权衡，预算模型则将这种权衡转化为可以直接执行的切换规则。

综合冻结结果可得以下结论：

1. Research 和 Coding 的有效前沿均为 DeepSeek-V4-Flash Max、DeepSeek-V4-Pro Max 和 Kimi K3；General 的前沿进一步包含 Qwen3.8-Max、Gemini-3.1-Pro (High) 和 GPT-5.6 Sol。
2. DeepSeek-V4-Flash Max 在三个场景中都是最低成本的可行模型。随着预算跨越表 3 所列成本门槛，最优模型按 Pareto 前沿顺序离散切换。
3. Coding 和 Research 从 DeepSeek-V4-Pro Max 升级至 Kimi K3 的 ICER 分别为 3.713059 和 2.973325 USD/utility，说明末端效用增益需要付出较高追加成本；General 的中段升级则存在较低 ICER。
4. 全体 FULL cohort 的成本-性能拟合在不同场景间没有统一的稳定函数形式。General 的饱和模型虽有较高 R^2 ，但 LOOCV error 为 9.802600，不能据此断言普遍存在边际收益递减。

5. 在本次输入规模、输出/输入比例及价格扰动网格内，三类场景的 nominal Pareto 成员均保持，说明冻结结论对已测试扰动具有稳健性。
6. Bootstrap 将 Q2 的 2000 次效用抽样传播至 Q3。Flash 在三个场景的 Pareto 概率均为 1.0000，General 中 Qwen3.8-Max 与 GPT-5.6 Sol 分别为 1.0000 和 0.9765；但该稳健性只针对效用估计不确定性。

本研究的限制包括：API 价格具有时间变动性；标准化工作负载不覆盖所有真实用户；Fable 的完整 fallback 成本和 GLM-5.2 的公开标准单价仍不可观测；可比较模型数量有限；成本-性能拟合是横截面统计关联而非因果关系。因此，本文结论应理解为在冻结价格、标准化工作负载和 FULL cohort 条件下的场景化选型规则，而不是对所有生产环境的永久排名。

数据与价格来源说明

本文使用问题二冻结的场景效用及其 bootstrap 接口，并使用 Q3 v1.0 冻结的工作负载、价格核验和最终结果表。价格依据冻结审计中记录的官方模型与 API 文档，包括 OpenAI、Anthropic、Google、DeepSeek、Moonshot/Kimi、阿里云百炼和智谱开放平台的官方资料；具体 SKU、配置、单价、日期和汇率信息以冻结审计记录为准。Q3 冻结版本为 v1.0，Q2 接口采用正式冻结版本。




图 4: 输入-输出比例变化下的 Pareto 结构




图 5: Bootstrap 抽样下模型进入 Pareto 前沿的概率